

## Основы обучения нейронных сетей

Также как и человеческий мозг, нейронная сеть (НС) способна к обучению. Аналогия с мозгом не заканчивается на структуре нейрона и их сети. Идея обучения НС также позаимствована из природы. Известно, что человеческий мозг способен к самообучению, причем достигает успехов зачастую, не зная природы процессов, лежащих в основе выполняемых действий. Однако непременным атрибутом обучения является многократное повторение и возможность немедленной оценки полученного результата. Обучение НС может проводиться в трех режимах: с учителем, без учителя и с подкреплением. Рассмотрим далее задачу в режиме обучения НС с учителем.

**Цель обучения НС с учителем** состоит в поиске (подборе) таких значений весов дуг  $w(u)$  в структуре орграфа  $G(X, U)$ , чтобы при заданных входных сигналах  $input(x)$  для нейронов входного слоя  $x \in X_{IN}$  получить выходные сигналы  $output(x)$  для нейронов выходного слоя  $x \in X_{OUT}$ , которые будут близки к ожидаемым значениям  $output^*(x)$ .

Набор входных сигналов и правильных (ожидаемых) выходных сигналов сети называется **обучающим примером**. Для обучения НС может быть использован не один, а несколько обучающих примеров, совокупность которых принято называть **выборкой** обучающих примеров. Рассмотрим далее особенности решения задачи обучения НС на некотором обучающем примере.

Для поиска весов дуг НС в пространстве  $[-1, 1]$  требуется **критерий**, который определяет, как правило, расстояние в той или иной метрике между полученным решением и ожидаемым (правильным) ответом:

$$E(w) \rightarrow \min, \quad (1)$$

где  $E(w)$  – непрерывная и дифференцируемая функция многих переменных, характеризующая ошибку полученного решения.

Решение этой задачи сводится к построению убывающей последовательности  $E^0(w), E^1(w), \dots, E^k(w), \dots$  где  $k$  – шаг обучения. При построении этой последовательности используются различные **правила останковки** процесса поиска. Например, можно задать фиксированное количество шагов обучения  $k_{\max}$  или условие  $|E^k(w) - E^{k-1}(w)| \leq \varepsilon$ , где  $\varepsilon$  – допустимая точность решения.

Для решения этой задачи используются **градиентные методы** оптимизации и их различные модификации. Суть этих методов сводится к уточнению (коррекции) весов дуг  $(x_i, x_j)$  на  $k$  – шаге обучения по следующим формулам:

$$w_{ij}^k = w_{ij}^{k-1} + \Delta w_{ij}^k, \quad (2)$$

$$\Delta w_{ij}^k = h^k p^k(w_{ij}), \quad (3)$$

где  $p^k(w_{ij})$  – направление движения (вектор) в многомерном пространстве поиска, а  $h^k$  – шаг, который надо сделать в этом направлении. Для начала обучения следует задать веса дуг  $w^0(u)$ . Эти веса выбираются случайным образом на отрезке  $[-1, 1]$  как ненулевые значения близкие к 0 или берутся из предыдущего сеанса обучения НС. Полагаем, что в начале обучения для каждой дуги сети  $\Delta w^0(u) = 0$ .

Из курса математики известно, что направление наискорейшего увеличения функции определяется вектором градиента  $\frac{dE}{dw}$ , отсюда и название этих методов. Т.к. в задаче требуется минимизация целевой функции (1), то двигаться надо в обратном направлении вектора градиента, т.е. в направлении антиградиента.

Обучение НС с применением градиентных методов требует определения антиградиента относительно всех слоев сети, что необходимо для правильного выбора направления  $p^k(w_{ij})$ . Эта задача имеет очевидное решение только для весов выходного слоя, где у нейронов нет исходящих дуг. Для нейронов других слоев используется метод обратного распространения ошибки, суть которого состоит в движении поиска от нейронов выходного слоя к нейронам других слоев в обратном порядке.

### Метод обратного распространения ошибки в НС

Рассмотрим далее этот метод при условии, что функция активации нейронов будет сигмовидная  $f(a) = \frac{1}{1+e^{-a}}$ , для которой известно, что:

$$f'(a) = f(a)(1 - f(a)). \quad (4)$$

Здесь  $a$  – входной сигнал нейрона  $x_j$ , который определяется по формуле:

$$a = \sum_{\forall x_i \in \Gamma^{-1}(x_j)} output(x_i)w(x_i, x_j), \quad (5)$$

В этом методе для критерия (1) используется функция следующего вида:

$$E = \frac{1}{2} \sum_{\forall x_j \in X_{out}} (output(x_j) - output^*(x_j))^2. \quad (6)$$

Функция (6) характеризует ошибку, полученную на нейронах выходного слоя, и определяется полусуммой расстояния между некоторым полученным решением и правильным ответом задачи в евклидовой метрике.

После дифференцирования функции (6) получим следующую формулу для определения градиента:

$$\frac{dE}{dw} = (output(x_j) - output^*(x_j)) \frac{df}{da} \frac{da}{dw}, \quad (7)$$

а после подстановки формулы (4) и замены направления на противоположное получим следующую формулу для определения антиградиента:

$$(output^*(x_j) - output(x_j)) output(x_j) (1 - output(x_j)) \frac{da}{dw}. \quad (8)$$

Для расчета вектора антиградиента **у нейронов выходного слоя**, у которых нет исходящих дуг (не зависит от  $W$ ), введем следующую поправку (ошибка в выходном сигнале у данного нейрона):

$$\delta(x_j) = (output^*(x_j) - output(x_j)) output(x_j) (1 - output(x_j)). \quad (9)$$

У нейронов скрытого слоя, у которых есть исходящие дуги, учтем поправку на его выходной сигнал по ошибкам на нейронах следующего слоя:

$$(output^*(x_j) - output(x_j)) = \sum_{\forall x_s \in \Gamma(x_j)} w_{js} \delta(x_s).$$

Тогда для расчета вектора антиградиента у **нейронов скрытого слоя** получим следующую формулу поправки:

$$\delta(x_j) = output(x_j)(1 - output(x_j)) \sum_{\forall x_s \in \Gamma(x_j)} w_{js} \delta(x_s). \quad (10)$$

Таким образом, вектор антиградиента (8), задающего направление поиска, определяется для каждого нейрона сети по следующей формуле:

$$\delta(x_j) \frac{da}{dw}, \quad (11)$$

а после дифференцирования функции (5) получим следующую формулу для каждого компонента антиградиента на  $k$ -ом шаге обучения:

$$p^k(w_{ij}) = \delta(x_j) output(x_i). \quad (12)$$

Расчет приращение веса дуги  $(x_i, x_j)$  в этом методе использует модифицированную следующим образом формулу (3):

$$\Delta w_{ij}^k = \eta \times p^k(w_{ij}) + \alpha \times \Delta w_{ij}^{k-1}, \quad (13)$$

где  $\eta$  и  $\alpha$  – параметры алгоритма, которые задаются учителем ( $\eta$  – скорость обучения,  $\alpha$  – момент обучения). Второе слагаемое в формуле (13) введено для сглаживания функции (6). Определение нового значения веса дуги  $w_{ij}^k$  в результате обучения на  $k$ -ом шаге производится по формуле (2). Рассмотрим далее алгоритмическую реализацию этого метода.

### Алгоритм обучения НС на основе метода обратного распространения ошибки

Пусть имеется НС, структура которой задана оргграфом  $G(X, U)$  с установленными начальными значениями весов дуг  $w^0(u)$ . Пусть имеется некоторый обучающий пример, включающий в себя:

- входные сигналы нейронов входного слоя  $\forall x \in X_{IN} : input(x)$ ,
- выходные сигналы нейронов выходного слоя  $\forall x \in X_{OUT} : output^*(x)$ .

Пусть учителем заданы следующие параметры алгоритма:  $\eta$ ,  $\alpha$ ,  $k_{max}$ . Тогда данный алгоритм будет сводиться к следующим действиям.

1. Положить:  $k = 0, \forall u \in U : \Delta w^0(u) = 0$
2. Рассчитать  $\forall x \in X : output^0(x)$  с помощью алгоритма последовательного распространения сигналов в НС
3. Найти оценку решения  $E^0(w)$  по формуле (6)
4. **ЦИКЛ** по шагам обучения  $k = 1, k_{max}$ 
  - 4.1. **ЦИКЛ** по всем дугам  $(x_i, x_j) \in U$  в обратном порядке
    - 4.1.1. **ЕСЛИ**  $x_j \in X_{OUT}$  **ТО** рассчитать  $\delta^k(x_j)$  по формуле (9), **ИНАЧЕ** рассчитать  $\delta^k(x_j)$  по формуле (10)


- 4.1.2. Рассчитать  $p^k(w_{ij})$  по формуле (12)
- 4.1.3. Рассчитать  $\Delta w_{ij}^k$  по формуле (13)
- 4.1.4. Рассчитать  $w_{ij}^k$  по формуле (2)
- 4.2. Рассчитать  $\forall x \in X : output^k(x)$  с помощью алгоритма последовательного распространения сигналов в НС
- 4.3. Найти оценку решения  $E^k(w)$  по формуле (6)

Примечание:

1. Для проведения расчетов  $output(x)$  рекомендуется использовать встроенный калькулятор <https://www.google.ru/>.
2. Округление сигналов нейрона следует проводить до второго знака после запятой по следующему правилу. Если значение после третьего знака после запятой больше, чем 0.005, то округлить значение второго знака после запятой в большую сторону, если меньше или равно 0.005, то оставить второй знак после запятой без изменения. Например:  $0.475 \approx 0.47$ ,  $0.4785 \approx 0.48$ ,  $0.4705 \approx 0.47$ .
3. Округление оценок  $E^0(w), E^1(w), \dots$  следует проводить аналогично, но до четвертого знака после запятой.

### ПРИМЕР

Обучить заданную нейронную сеть с сигмовидной функцией активации нейронов с помощью алгоритма обратного распространения ошибки при условии, что  $input(0)=0.9$ ,  $input(1)=0.4$ ,  $output^*(4)=1$ ,  $\eta=0.7$ ,  $\alpha=0.3$ ,  $k_{\max}=1$ .



### РЕШЕНИЕ

1. Положим:  $k = 0$ ,  $\forall u \in U : \Delta w^0(u) = 0$
2. Рассчитаем  $\forall x \in X : output^0(x)$  с помощью алгоритма последовательного распространения сигналов в НС.

2.1. Определим выходные сигналы для нейронов входного слоя:

$$output(x_0) = input(x_0) = 0.9$$

$$output(x_1) = input(x_1) = 0.4$$

2.2. Рассчитаем входной и выходной сигналы нейрона  $x_2$  с прообразами

$$\Gamma^{-1}(x_2) = \{x_0, x_1\} :$$

$$input(x_2) = 0.9 \times 0.9 + 0.4 \times 0.6 = 1.05$$

$$output(x_2) = f(input(x_2)) = 0.74077 \approx 0.74$$

2.3. Рассчитаем входной и выходной сигналы нейрона  $x_3$  с прообразами

$$\Gamma^{-1}(x_3) = \{x_0, x_1\} :$$

$$input(x_3) = 0.9 \times 0.7 + 0.4 \times 0.6 = 0.87$$

$$output(x_3) = f(input(x_3)) = 0.704745 \approx 0.7$$

2.4. Рассчитаем входной и выходной сигналы нейрона  $x_4$  с прообразами

$$\Gamma^{-1}(x_4) = \{x_2, x_3\} :$$


$$input(x_4) = 0.74 \times (-0.9) + 0.7 \times (-0.5) = -1.016 \approx -1.02$$

$$output(x_4) = f(input(x_4)) = 0.2658 \approx 0.27$$

3. Оценим полученное решение по формуле (6):

$$E^0(w) = \frac{1}{2} \sum_{\forall x_j \in X_{OUT}} (output(x_j) - output^*(x_j))^2 = 0.269512 \approx 0.2695$$

Результаты расчетов приведены ниже.



k = 0



X	Прообразы X	input(X)	output(X)
0	-	0.9	0.9
1	-	0.4	0.4
2	0,1	1.05	0.74
3	0,1	0.87	0.7
4	2,3	-1.02	0.27

$E^0(w)$ : 0,2695

4. Положим шаг обучения  $k = 1$

4.1. Определим для нейрона  $x_4$  значение  $\delta^k(x_j)$  по формуле (9):

$$\delta^1(x_4) = (1 - 0.27) \times 0.27 \times (1 - 0.27) = 0.143883 \approx 0.14$$

Рассчитаем для дуги  $(x_3, x_4)$ :

$$p^1(w_{34}) = 0.14 \times 0.7 = 0.098 \approx 0.1$$

$$\Delta w_{34}^1 = 0.7 \times 0.1 + 0.3 \times 0 = 0.07$$

$$w_{34}^1 = -0.5 + 0.07 = -0.43$$

Рассчитаем для дуги  $(x_2, x_4)$  :

$$p^1(w_{24}) = 0.14 \times 0.74 = 0.1036 \approx 0.1$$

$$\Delta w_{24}^1 = 0.7 \times 0.1 + 0.3 \times 0 = 0.07$$

$$w_{24}^1 = -0.9 + 0.07 = -0.83$$

4.2. Определим для нейрона  $x_3$  значение  $\delta^k(x_j)$  по формуле (10):

$$\delta^1(x_3) = 0.7 \times (1 - 0.7) \times 0.14 \times (-0.5) = -0.0147 \approx -0.01$$

Рассчитаем для дуги  $(x_1, x_3)$  :

$$p^1(w_{13}) = -0.01 \times 0.4 = -0.004 \approx 0$$

$$\Delta w_{13}^1 = 0.7 \times 0 + 0.3 \times 0 = 0$$

$$w_{13}^1 = 0.6 + 0 = 0.6$$

Рассчитаем для дуги  $(x_0, x_3)$  :

$$p^1(w_{03}) = -0.01 \times 0.9 = -0.009 \approx -0.01$$

$$\Delta w_{03}^1 = 0.7 \times (-0.01) + 0.3 \times 0 = -0.01$$

$$w_{03}^1 = 0.7 - 0.01 = 0.69$$

4.3. Определим для нейрона  $x_2$  значение  $\delta^k(x_j)$  по формуле (10):

$$\delta^1(x_2) = 0.74 \times (1 - 0.74) \times 0.14 \times (-0.9) = -0.02424 \approx -0.02$$

Рассчитаем для дуги  $(x_1, x_2)$  :

$$p^1(w_{12}) = -0.02 \times 0.4 = -0.008 \approx -0.01$$

$$\Delta w_{12}^1 = 0.7 \times (-0.01) + 0.3 \times 0 = -0.007 \approx -0.01$$

$$w_{12}^1 = 0.6 - 0.01 = 0.59$$


Рассчитаем для дуги  $(x_0, x_2)$  :

$$p^1(w_{02}) = -0.02 \times 0.9 = -0.018 \approx -0.02$$

$$\Delta w_{02}^1 = 0.7 \times (-0.02) + 0.3 \times 0 = -0.014 \approx -0.01$$


$$w_{02}^1 = 0.9 - 0.01 = 0.89$$

Результаты обучения нейронной сети на шаге  $k = 1$  приведены ниже.



$(x_i, x_j)$	$w_{ij}^0$	$\Delta w_{ij}^0$	$\delta(x_j)$	$p^1(w_{ij})$	$\Delta w_{ij}^1$	$w_{ij}^1$
(3, 4)	-0.5	0	0.14	0.1	0.07	-0.43
(2, 4)	-0.9	0	0.14	0.1	0.07	-0.83
(1, 3)	0.6	0	-0.01	0	0	0.6
(0, 3)	0.7	0	-0.01	-0.01	-0.01	0.69
(1, 2)	0.6	0	-0.02	-0.01	-0.01	0.59
(0, 2)	0.9	0	-0.02	-0.02	-0.01	0.89

5. Рассчитаем  $\forall x \in X : output^0(x)$  с помощью алгоритма последовательного распространения сигналов в НС и оценим полученное решение (результаты расчетов приведены ниже).



k = 1



X	Прообразы X	input(X)	output(X)
0	-	0.9	0.9
1	-	0.4	0.4
2	0,1	1.04	0.74
3	0,1	0.86	0.7
4	2,3	-0.92	0.29

$E^1(w):$

**Вывод:** За один шаг обучения нейронной сети с помощью данного алгоритма мы снизили ошибку с 0,2695 до 0.255.