


Информатика для ВТУЗОВ



Соснін Владимир Валерьевич, к.т.н.
Балакшин Павел Валерьевич, к.т.н.

- Основы теории информации
- Сжатие компьютерных данных
- Помехоустойчивое кодирование
- Архитектура ЭВМ
- Организация компьютерных сетей
- Работа с офисными пакетами
- Программное обеспечение профессионального программиста



Требования к слушателям: освоенный школьный курс информатики.



Информатика – дисциплина, изучающая свойства и структуру информации, закономерности ее создания, преобразования, накопления, передачи и использования.

Англ: informatics = information technology + computer science + information theory

Важные даты

- 1956 – появление термина «информатика» (нем. Informatik, Штейнбух)
- 1968 – первое упоминание в СССР (информология, Харкевич)
- 197X – информатика стала отдельной наукой
- 4 декабря – день российской информатики



Международный стандарт ISO/IEC 2382:2015

«Information technology – Vocabulary» (вольный пересказ):

Информация – знания относительно фактов, событий, вещей, идей и понятий.

Данные – форма представление информации в виде, пригодном для передачи или обработки.

- Что есть предмет информатики: информация или данные?
- Как измерить информацию? Как измерить данные?
Пример: «Байкал — самое глубокое озеро Земли».



Некоторые признаки классификации информации

- **Точность.**
IT-область: методы округления, сжатие медиа-данных.
- **Ценность.**
IT-область: защита информации.
- **Стадия обработки** (исходная, промежуточная и результирующая).
IT-область: программирование, базы данных.
- **Полнота** (недостаточная, достаточная, избыточная).
IT-область: сжатие данных.
- **Близость к первоисточнику** (первичная, вторичная).
IT-область: интеллектуальный анализ данных, Big Data, базы данных.



Некоторые признаки классификации информации (2)

- **Методы получения** (эмпирическая, теоретическая, эмпирико-теоретическая).
IT-область: имитационное моделирование, компьютерная математика.
- **Актуальность**. IT-область: система обновлений ПО, системы управления содержанием.
- **Достоверность**. IT-область: MD5-суммы, открытые сертификаты (https).
- **Роль при передаче** (входная, выходная и внутренняя).
IT-область: компьютерные сети, аппаратные интерфейсы компьютера.
- **Изменчивость** (постоянная, переменная, смешанная).
IT-область: кэширование, системы хранения данных.
- **Доступность** (открытая, закрытая, конфиденциальная, секретная)
IT-область: криптография.

ТЦ «СПБ—МАДРИД» – мнемотехническая аббревиатура для запоминания перечисленных признаков классификации, т.е. торговый центр «Санкт-Петербург—Мадрид».



Количество информации \equiv информационная энтропия – это численная мера непредсказуемости информации. Количество информации в некотором объекте определяется непредсказуемостью состояния, в котором находится этот объект.

Пусть $i(s)$ — функция для измерения количеств информации в объекте s , состоящем из n независимых частей s_k , где k изменяется от 1 до n . Тогда **свойства меры количества информации $i(s)$** таковы:

- Неотрицательность: $i(s) \geq 0$.
- Принцип предопределённости: если об объекте уже все известно, то $i(s) = 0$.
- Аддитивность: $i(s) = \sum i(s_k)$ по всем k .
- Монотонность: $i(s)$ монотонна при монотонном изменении вероятностей.



- **Классическое определение** (существует только n равновозможных исходов эксперимента, из них m исходов приведут к событию A)

$$p(A) = m/n$$

- **Статистическое определение** (в результате проведённых n экспериментов события A возникло m раз)

$$p(A) = \lim_{n \rightarrow \infty} \frac{m}{n}$$

- **Свойства вероятности**

$$0 \leq p(A) \leq 1,$$

сумма вероятностей всех возможных несовместных событий равна 1

Мера количества информации по Хартли



Система S может находиться в одном из N равновероятных состояний. Вероятность каждого из состояний $p = 1/N$. Передадим сообщение о выпавшем состоянии S , используя двоичное сообщение длины d :

$$2^d \geq N \rightarrow d \geq \log_2 N$$

Значит, для однозначного описания системы требуется $\log_2 N$ бит. По определению Хартли, количество информации в системе S равно

$$i_H(s) = \log_x N = -\log_x p.$$



Ральф Хартли
(1880--1970)

Единицы измерения количества информации:

$$i_H = (\text{lb } N \text{ бит} = \text{lb } N \text{ Шн} = \text{lb } N \text{ Sh}) = \log_3 N \text{ трит} = (\lg N \text{ харт} = \lg N \text{ Hart} = \lg N \text{ дит}) = \ln N \text{ нат}$$

Какова этимология названий единиц измерения? Сколько дит содержится в 33 битах?

Ответ 1: (bit \rightarrow binary digit), (dit \rightarrow decimal digit), (Шн \rightarrow Шеннон), (харт \rightarrow Хартли) и т. д.

Ответ 2: т. к. $33 \text{ бит} = \log_2 N$, то $\log_{10} N = x \text{ дит}$, отсюда найдём x через N : $x = \log_{10} 2^{33} \approx 9,9 \text{ дит}$.



Пример 1. Ведущий загадывает число от 1 до 64. Какое количество вопросов типа «да-нет» понадобится, чтобы гарантировано угадать число?

- Первый вопрос: «Загаданное число меньше 32?». Ответ: «Да».
- Второй вопрос: «Загаданное число меньше 16?». Ответ: «Нет».
- ...
- Шестой вопрос (в худшем случае) точно приведёт к верному ответу.
- Значит, в соответствии с мерой Хартли в загадке ведущего содержится ровно $\log_2 64 = 6$ бит непредсказуемости (т. е. информации).

Пример 2. Ведущий держит за спиной ферзя и собирается поставить его на произвольную клетку доски. Насколько непредсказуемо его решение?

- Всего на доске 8×8 клеток, а цвет ферзя может быть белым или чёрным, т. е. всего возможно $8 \times 8 \times 2 = 128$ равновероятных состояний.
- Значит, количество информации по Хартли равно $\log_2 128 = 7$ бит.



Экспериментатор одновременно подбрасывает монету (М) и кидает игральную кость (К).
Какое количество информации содержится в эксперименте (Э)?

Аддитивность:

$$i(\text{Э}) = i(\text{М}) + i(\text{К}) \Rightarrow i(12 \text{ исходов}) = i(2 \text{ исхода}) + i(6 \text{ исходов}): \log_x 12 = \log_x 2 + \log_x 6$$

Неотрицательность:

Функция $\log_x N$ неотрицательно при любом $x > 1$ и $N \geq 1$.

Монотонность:

С увеличением $p(\text{М})$ или $p(\text{К})$ функция $i(\text{Э})$ монотонно возрастает.

Принцип предопределённости:

При наличии всегда только одного исхода (монета и кость с магнитом) количество информации равно нулю: $\log_x 1 + \log_x 1 = 0$.

Мера количества информации по Шеннону



Мера Хартли подходит лишь для систем с равновероятными состояниями. Если состояния системы S не равновероятны, используют меру Шеннона:

$$i(S) = - \sum_{i=1}^N p_i \cdot \log_2 p_i,$$

где N – число состояний системы,
 p_i – вероятность того, что система S находится в состоянии i (сумма всех p_i равна 1).



Клод Шеннон
(1916–2001)

Формула Хартли является частным случаем формулы Шеннона!

Пример 1. Количество информации в акте подбрасывания обычной монеты по формуле Хартли равно $\log_2 2 = 1$ бит. По формуле Шеннона получим то же: $i_{s_1} = -0,5 \cdot \log_2 0,5 - 0,5 \cdot \log_2 0,5 = 1$ бит.

Пример 2. При подбрасывании монеты со смещённым центром тяжести количество непредсказуемости становится меньше: $i_{s_2} = -0,75 \cdot \log_2 0,75 - 0,25 \cdot \log_2 0,25 \approx 0,8$ бит.



Шулер наугад вытаскивает одну карту из стопки, содержащей 9 известных ему карт: 3 джокера, 3 туза, 1 король, 1 дама и 1 валет. Какое количество информации для шулера содержится в этом событии s ?

$$\text{Вероятность вытащить} \left\{ \begin{array}{l} \text{джокера} \\ \text{туза} \\ \text{короля} \\ \text{даму} \\ \text{валета} \end{array} \right\} \text{ равна } \left\{ \begin{array}{l} 3/9 = 1/3 \\ 3/9 = 1/3 \\ 1/9 \\ 1/9 \\ 1/9 \end{array} \right.$$

Количество информации, выраженное в тритах, равно:

$$\begin{aligned} i(s) &= -\left(\frac{1}{3} \cdot \log_3 \frac{1}{3} + \frac{1}{3} \cdot \log_3 \frac{1}{3} + \frac{1}{9} \cdot \log_3 \frac{1}{9} + \frac{1}{9} \cdot \log_3 \frac{1}{9} + \frac{1}{9} \cdot \log_3 \frac{1}{9}\right) = \\ &= \frac{1}{3} + \frac{1}{3} + \frac{2}{9} + \frac{2}{9} + \frac{2}{9} = 1\frac{1}{3} \approx \log_3 5 \text{ vs } \log_3 14 \end{aligned}$$



Задача. Монета имеет смещённый центр тяжести. Вероятность выпадения «орла» – 0,25, вероятность выпадения «решки» – 0,75. Какое количество информации содержится в одном подбрасывании?

Решение

- Пусть монета была подброшена N раз ($N \rightarrow \infty$), из которых «решка» выпала K раз, «орёл» — M раз (очевидно, что $N = M + K$).
- Количество информации в N подбрасываниях: $i_N = M * i(\text{«решка»}) + K * i(\text{«орёл»})$.
- Тогда среднее количество информации в одном подбрасывании:
$$i_1 = i_N / N = (M/N) * i(\text{«решка»}) + (K/N) * i(\text{«орёл»}) = p(\text{«решка»}) * i(\text{«решка»}) + p(\text{«орёл»}) * i(\text{«орёл»}).$$
- Подставив формулу Хартли для i , окончательно получим:
$$i_1 = -p(\text{«решка»}) * \log_x p(\text{«решка»}) - p(\text{«орёл»}) * \log_x p(\text{«орёл»}) \approx 0,8 \text{ бит.}$$